

基于 ADS-B 训练的跨洋航班 ADS-C 长缺失轨迹恢复方法

面向跨洋场景的稀疏 ADS-C 轨迹恢复方法：基于 ADS-B 构造训练与高度结构化建模

摘要：本文面向跨洋航班场景下 ADS-C 轨迹长时间缺失、观测稀疏且时间不规则的问题，提出一种数据构造与模型设计相结合的三维轨迹恢复方法。针对 ADS-C 数据难以获取连续真值、难以直接开展监督学习的现实约束，本文利用高时间分辨率的 ADS-B 数据，构造与 ADS-C 观测形态一致的稀疏采样与长缺失训练样本，从而为模型提供可控且具代表性的监督信号。在此基础上，构建双向时序主干网络，对经度、纬度与高度进行统一建模并完成三维轨迹的初步恢复。

进一步考虑到高度维度对缺失区间边界条件具有更强依赖且误差特性显著不同，本文设计高度专项处理分支，将高度恢复分解为“整体趋势刻画”与“局部残差修正”两个层次：首先基于边界锚点构造线性基线，并结合主干输出进行受限偏移以形成主趋势；随后通过注意力聚合与序列解码提取局部非线性偏差，并引入轻量级时序细化模块增强全局一致性。为避免局部修正破坏整体连续性，进一步引入基于缺失片段风险等级的约束机制，对残差进行强度调制与幅值限制。

实验结果表明，所提方法在高度恢复指标上显著优于现有对比方法，同时在计算复杂度与训练效率之间保持良好平衡，验证了“数据驱动的稀疏建模 + 高度分层约束”的有效性。该方法为长缺失轨迹恢复问题提供了一种兼顾可学习性与物理合理性的解决思路。

1 研究背景

航空器轨迹数据是空中交通管理、运行态势感知、冲突探测、飞行效率分析、排放评估和运行风险预警的重要基础信息。随着全球空中交通流量持续增长，基于轨迹的运行（Trajectory-Based Operations, TBO）逐步成为现代空管系统的重要发展方向，轨迹预测与轨迹恢复的重要性日益凸显：前者为空中交通流管理、冲突探测和运行预警提供未来状态依据，后者为观测缺失条件下的轨迹重建、运行分析和安全评估提供连续可信的数据支撑。已有综述指出，航空轨迹建模研究已经由传统基于物理机理、飞行动力学和规则外推的方法，逐渐转向基于大规模运行数据的学习方法，形成了涵盖循环神经网络、注意力机制、Transformer、多模态融合以及概率预测等在内的多种技术路线[1][2]。

当前航空轨迹研究大量依赖广播式自动相关监视（Automatic Dependent Surveillance-Broadcast, ADS-B）数据，ADS-B 具有更新频率高、观测精细、覆盖区域广等优点，在陆基接收设施完善的区域能够提供较为连续的高频航迹观测，因此成为航迹预测[3]、意图识别[4]、异常检测[5]、滑行冲突规避[6]和飞行运行分析[7]的主要数据来源。然而，ADS-B 的实际可用性高度依赖地面接收网络，海洋、极地以及地面基础设施薄弱的偏远空域长期存在覆盖不足甚至观测中断问题，在长航程尤其是跨洋巡航阶段，研究者能够获取的并非高频连续轨迹，

而往往是由少量锚点、间断观测和不规则时间间隔构成的稀疏监视序列。近年来,针对 ADS-B 失效的航空器轨迹预测问题,已有研究开始引入 Bi-LSTM 等深度学习方法以进行短期预测提升繁忙空域飞行安全[8],并进一步发展出面向稀疏卫星观测条件的预测框架[9],以增强模型对不连续观测信息的利用能力和鲁棒性。然而,这些工作总体上仍更多面向短时预测或局部中断补偿,而非长段中间恢复这一更困难的问题。

与 ADS-B 相比,契约式自动相关监视 (Automatic Dependent Surveillance-Contract, ADS-C) 采用合同式报告机制接收数据,与陆基接收条件较好区域中可获得的高频连续 ADS-B 轨迹不同,ADS-C 所提供的通常不是细粒度连续航迹,而是由少量离散报告点构成的稀疏监视序列,其中相邻观测之间往往间隔较长,中间缺少连续轨迹信息。但是通过依托卫星通信链路,ADS-C 可以在海洋和偏远区域持续提供位置报告,是跨洋和长航程运行中的重要补充监视手段。OpenSky 2025 报告表明,将 ADS-C 与 ADS-B 融合后,可以显著改善跨大西洋、非洲等区域原本覆盖不足航段的轨迹重建质量,并提升后续油耗、排放和运行分析的可靠性[10]。国内相关研究和行业资料表明,海洋及内陆偏远空域由于缺乏地面监视基础设施,持续监视通常依赖卫星通信支持下的 ADS-C 以及星基 ADS-B 等手段,而传统地基监视系统难以实现对上述区域的连续覆盖[11]。

现有航空轨迹研究虽然发展迅速,但其主要针对的是终端区、航路区或一般 ADS-B 观测条件下的未来轨迹预测问题,相关方法更重视时空依赖建模、运行语义融合、飞行模式识别和多步预测精度[12][14][15],而对稀疏边界条件下的中间恢复这一场景关注有限。与此同时,高度维度相较于平面位置更容易受到边界条件、局部波动和非线性变化的共同影响。已有研究已经开始意识到这一点,例如有工作提出了针对于非塔台航站楼空域的高度感知轨迹预测模型,显著增强模型捕捉复杂垂直飞行模式的能力[13]。

综上,本文关注的并非一般意义上的轨迹预测问题,而是面向跨洋巡航场景、以稀疏 ADS-C 锚点为约束的长缺失轨迹恢复问题。该问题一方面受限于真实 ADS-C 数据稀疏、缺乏连续真值,难以直接开展有效监督学习;另一方面又要求恢复结果在极弱观测条件下同时满足整体合理性、边界稳定性和局部形态自然性,尤其高度维度的恢复更具挑战性。基于此,本文以 ADS-B 数据为训练基础,通过构造与 ADS-C 观测形式一致的稀疏样本,实现面向真实场景的可监督训练;同时,围绕长缺失轨迹恢复中的高度敏感问题,进一步引入针对高度维度的专门建模策略,以提升跨洋稀疏场景下轨迹恢复的精度、稳定性和实际可用性。

2 国内外研究现状

2.1 航空轨迹预测与恢复方法

航空轨迹预测与恢复是航空运行智能化研究中的基础问题,其研究目标是从历史飞行状态中刻画航空器运动规律,并进一步为空中交通流管理、冲突探测、运行监控和飞行性能评估提供可计算、可推演的轨迹信息支撑。早期相关研究主要依赖状态估计方法与飞行动力学

方法[16][17],这类方法通常具有较强的可解释性,但对模型假设和先验条件依赖较大,在复杂运行环境、多源扰动以及大规模历史数据可获得的背景下,其表达能力逐渐受到限制。近年来,随着监视数据规模持续扩展和计算能力快速提升,航空轨迹建模已明显转向以数据驱动为核心的学习方法,逐步形成了包括循环神经网络、注意力机制、Transformer、概率预测等多条技术路线[1][2]。

循环神经网络及其变体是航空轨迹学习方法的重要起点。Ayala 等围绕神经网络在航空轨迹预测中的性能问题开展了系统实验分析,证明了基于数据驱动的时序模型能够有效学习飞行轨迹中的非线性演化规律[18]。随着时序建模需求不断提升,研究者开始进一步融合卷积、双向循环和多头注意力等结构。Xu 等提出结合 CNN、BiLSTM 与多头注意力机制的轨迹预测方法[19],通过卷积提取局部空间特征、利用双向循环建模时间依赖,并借助注意力增强关键模式表达,从而提升了复杂轨迹场景下的预测能力。Ma 等则提出基于 Attention-TCN-GRU 的四维轨迹预测模型[20],将时间卷积网络与门控循环结构结合起来,以增强模型对长时间尺度动态变化的捕获能力。这些工作表明,围绕时序依赖、局部模式和长程信息表达的网络结构改进,已经成为航空轨迹学习方法的重要演进方向。

随着预测任务的逐渐深入,研究从传统循环结构转化为更强的序列编码与全局依赖建模。Guo 等提出了 FlightBERT[21],通过二进制编码表示方法对飞行轨迹进行建模,表明 BERT 类结构能够在航空轨迹序列表示学习中取得良好效果。在此基础上,Guo 等提出 FlightBERT++[22],将非自回归多时域预测框架引入飞行轨迹建模中,以同时支持多个预测时域下的轨迹推演,提高了模型在多步预测场景中的效率与性能。Ge 等提出 PC-Transformer[23],通过三阶段渐进式架构与概率建模机制增强模型对未来轨迹分布的表达能力,解决了大规模飞行数据中高精度概率轨迹预测的挑战。为了提升多时域预测性能,Guo 等提出基于时频小波变换的轨迹预测方法[24],将时间域与频域信息联合用于轨迹建模,在保留单时域预测准确性的同时显著提升多时域预测的准确性。Dai 等提出 CoDRE-Net[25],通过同时加强空间和频域的轨迹特征表示,以提高预测准确性。

除了模型结构本身的演进外,近年来研究还同时考虑复杂运行场景下的语义信息、意图信息和交互关系建模对于轨迹预测结果的影响。针对终端区轨迹预测场景,Dong 等基于时间和空间注意力机制构建 ST-Transformer[26],通过更好地整合轨迹特征的时间序列相关性和轨迹间潜在的空间交互信息,实现准确预测。Yin 等从局部历史轨迹中挖掘飞行意图信息[27],从而提升终端区轨迹预测的鲁棒性和准确性。面向多航空器联合预测问题,Chu 等提出了结合飞行模式引导和社会交互建模的长短期记忆网络,显著提升了繁忙时段的复杂交通环境中的预测精度和准确度[28]。这些研究反映出,当前航空轨迹预测方法已经不再局限于单纯的位置时间序列拟合,而是越来越强调多源信息融合、飞行语义表达和复杂环境适应能力。

现有航空轨迹预测与恢复方法研究已经取得了较为丰富的进展,然而,这些代表性工作,

其主要解决终端区、航路区或 ADS-B 连续观测条件下的未来轨迹预测问题，而对于少量锚点约束下的中间长缺失轨迹恢复问题，尤其是跨洋稀疏监视条件下的长缺失轨迹重建，尚未形成与其问题特征相匹配的系统性研究框架。虽然现有轨迹学习方法为本文提供了重要的方法基础，但其研究目标和问题设定与本文关注的跨洋稀疏 ADS-C 轨迹恢复任务之间仍存在明显差异。

2.2 稀疏观测条件下的轨迹恢复方法

与一般 ADS-B 连续观测条件下的轨迹预测相比，稀疏观测条件下的轨迹恢复问题更为复杂，其观测数量减少，且监视序列通常表现为少量离散锚点、较长时间间隔和明显的不规则采样，模型难以依赖完整历史轨迹进行稳定推断。在航空领域，相关研究最初主要围绕 ADS-B 失效和观测中断展开。Yang 等针对 ADS-B 失效条件下的航空器轨迹预测问题，提出了基于 Bi-LSTM 的轨迹推断方法，结合历史飞行数据进行短期预测，并将其用于繁忙空域中的安全辅助分析[8]。该研究表明，当监视数据出现缺失或信号中断时，传统依赖连续观测的建模方式将明显受限，可以利用深度学习方法结合历史数据进行轨迹推断，但是这类工作主要面向失效后的短时轨迹预测。Wang 等提出一种端到端的飞行轨迹补值方法[29]，构建了由轨迹编码、轨迹预测和轨迹重建组成的端到端框架，用于从不完整短期轨迹中恢复完整轨迹。

在跨洋偏远地区，使用卫星观测飞行数据是对地面监视系统的重要补充方式，但是卫星传感具有的局限常常导致收集的数据极为稀疏且持续时间短，为解决此问题，Shan 等分层集成 CNN、LSTM 和 Transformer 模块[9]，捕捉局部机动、中期趋势和长期依赖关系，并通过在 ADS-B 数据集上进行测试证明了该方法在下一代基于卫星的空中交通检测系统的潜力。Sun 等提出将 ADS-C 与 ADS-B 融合可以显著改善跨大西洋、非洲等覆盖不足区域的轨迹重建质量，并提升后续油耗、排放和运行分析的可靠性[10]，侧面说明在海洋及偏远空域中，ADS-C 是支撑长航程、跨洋场景轨迹重建的重要数据基础。

由于航空领域内与本文完全同背景的问题研究仍较有限，其他时空轨迹场景中的稀疏恢复方法为本研究提供了重要参照。针对船舶跟踪数据的缺失问题，Galdelli 等提出了 BF-Bi LSTM 方法[30]，用于捕捉数据补缺轨迹前后的后向时间依赖关系，在船舶和飞行轨迹数据上验证了该方法对时空缺口补全的有效性，该研究提供了同时使用长时间缺失段左右上下文进行高质量插补的解决思路。针对稀疏车辆观测数据重建问题，Ma 等[31]提出一种结合隐马尔可夫模型和双向 Dijkstra 算法的改进映射匹配算法以确保轨迹重建输入数据的高质量，随后使用分段三次 Hermite 插值多项式算法重建车辆轨迹。Guo 等则面向稀疏的路口车辆交叉轨迹的场景开展研究，提出基于 Dijkstra 轨迹先验的混合物理-数据框架，同时结合时空约束和运动过程推断来重建环岛等复杂场景中的车辆轨迹。这些工作虽然并非针对航空器轨迹，但在问题特征上与本文具有较强相似性，都需要在少量边界信息约束下恢复长时间间隔中的中间轨迹形态。

以上相关工作说明,针对于稀疏场景中的轨迹恢复问题,研究者通过双向序列建模等方法以提升预测模型在不连续观测条件下的表现。然而,对于跨洋巡航场景下以稀疏 ADS-C 锚点为约束的长段中间恢复问题,仍缺乏专门面向其场景特征的方案。

2.3 飞机航行高度维度建模方案

在现有航空轨迹建模研究中,多数方法通常将经度、纬度和高度作为统一状态变量纳入同一时序预测框架中处理,其主要目标是通过共享的特征提取和时序编码结构完成三维或四维轨迹的整体建模。这种整体建模思路在一般轨迹预测任务中具有一定有效性,但对于长缺失轨迹恢复问题而言,高度维度所面临的约束和恢复难点通常比平面位置更加突出。

早期针对垂直维度特殊性的研究主要集中在飞行爬升阶段。Alligier 和 Gianazza[32]基于大规模多机场运行数据,他们发现影响爬升阶段预测精度的因素不仅包括轨迹序列本身,还与飞机质量、速度意图以及具体运行条件等因素密切相关。Verdonk 等[33]利用机器学习方法分析空中交通运行因素对垂直维度的影响,并据此增强对飞行轨迹垂直过程的预测能力。Rohani 等[34]利用历史飞行数据对航空器性能参数进行估计,同时考虑阻力系数、初始重量等密切相关的参数,从而更准确地反映轨迹预测中的高度变化过程。虽然这些研究并未直接提出针对高度维度的专门建模框架,但已从侧面反映出,高度变化与部分运行参数之间存在更紧密的联系,对于一些因素的变化更为明显。

近年来,已有少量研究开始显式强调高度维度的特殊性。面向非塔台航站楼空域中频繁高度变化带来的轨迹预测挑战,Zhu 等[13]提出高度感知轨迹预测模型 ACTrajNet,通过独立提取高度特征和动态融合机制增强模型捕捉复杂垂直飞行模式的能力。Wu 等[35]提出 FlightPatchNet 采用差分编码用于多步飞行轨迹预测,其中经纬度使用一阶差分编码,而高度保留原始数值形式,从而整合跨不同尺度和变量的多尺度时间特征。在四维轨迹生成中,Pepper 等[36]提出的面向特定扇区的概率式轨迹生成方法对平面路径与垂直过程采用分步建模方式,将平面航迹生成与爬升、下降剖面建模分开进行,再通过耦合算法生成完整的四维轨迹。Jarry 等[37]直接以垂直剖面生成为目标,利用 OpenSky 提供的 ADS-B 与 Mode S EHS 开放数据训练 Neural ODE 模型,对航空器垂直动态进行连续时间建模,并生成具有物理一致性的高度变化过程。这说明在相关研究中,垂直过程已经不再总是作为统一坐标序列中的一个普通分量处理,而是可以根据任务需要单独建模。

综上,现有研究已经初步表明,高度维度在航空轨迹建模中并不完全等同于平面位置,其变化过程往往与飞行阶段、运行参数和边界条件存在更紧密的联系。然而,这些研究总体上仍主要服务于未来轨迹预测或完整轨迹生成任务,对本文所关注的长缺失恢复场景下高度维度的边界约束、整体趋势与局部非线性之间的协调问题,仍缺乏针对性的结构化建模方法。

2.4 研究动机

针对上述研究现状,本文的研究动机主要来源于跨洋场景下稀疏轨迹恢复所面临的实际

需求与方法挑战。一方面，现有航空轨迹研究多数依赖 ADS-B 连续观测数据，而在真实跨洋巡航阶段，监视信息往往主要表现为由少量 ADS-C 报告点组成的稀疏、不规则序列。这类观测在时间分辨率和轨迹完整性方面存在明显局限，因而难以直接满足运行分析、安全评估等任务对连续轨迹信息的需求。另一方面，真实 ADS-C 数据天然稀疏，长时间间隔内通常缺乏连续真值，给数据驱动模型的训练和验证带来了较大困难。相比之下，ADS-B 数据具有分辨率高、连续性较好和样本规模较大的特点，为构造监督信号提供了可行基础，因此，如何利用 ADS-B 数据模拟 ADS-C 的观测形态并形成可用于训练的样本，是开展相关研究的重要前提。

此外，在长缺失恢复任务中，高度维度往往比平面位置更容易受到边界条件、局部波动和非线性变化的影响，若仍采用与经纬度完全一致的统一建模方式，恢复结果可能在边界衔接、局部细节和整体趋势上出现偏差。基于以上考虑，本文围绕跨洋稀疏 ADS-C 轨迹恢复问题展开研究，重点探讨基于 ADS-B 构造训练样本的可监督恢复方法，以及面向高度维度的结构化建模设计，以期提升长缺失轨迹恢复的精度、稳定性和实际应用价值。

2.5 创新点

（1）面向跨洋稀疏场景的样本构造方法

针对跨洋航班场景下 ADS-C 报文天然稀疏、时间不规则且连续真值难以获取，本文利用高时间分辨率的 ADS-B 数据构造与 ADS-C 观测形态相匹配的训练样本，将真实场景中难以直接开展监督学习的轨迹恢复问题转化为可训练、可验证的监督学习任务，为跨洋场景下长缺失轨迹恢复提供了可行的数据基础。

（2）面向真实 ADS-C 稀疏分布的分层样本构造与课程采样机制

针对跨洋航班长缺失轨迹恢复任务中训练样本恢复难度差异较大、训练分布与真实应用场景之间存在偏移的问题，本文提出一种结合真实 ADS-C 稀疏分布特征的分层样本构造与课程采样方法。首先依据真实 ADS-C 轨迹的时间间隔分布以及连续缺失跨度特征，对基于 ADS-B 构造的训练样本进行分层组织；在此基础上，通过渐进式课程训练方式，使模型在训练初期优先学习低缺失率、短跨度样本，后期过渡到中长缺失样本和更接近真实稀疏形态的样本，从而兼顾训练过程的稳定性与模型对真实场景的适应能力。

（3）面向高度恢复的两阶段建模方法

针对传统统一回归方式难以兼顾高度恢复中的边界衔接、整体趋势和局部变化的问题，本文提出一种面向高度维度的两阶段建模方法。该方法首先利用缺失区间两侧锚点构造满足边界约束的主趋势，以表征高度变化的整体走向；随后对真实高度相对于主趋势的偏离部分进行学习，以补充局部细节。通过这种分阶段的建模方式，使恢复结果在整体趋势和局部衔接方面更加稳定自然。

3 XXX 方法

3.1 问题描述

本文面向 ADS-C 稀疏观测场景中的长缺失轨迹恢复问题，采用 ADS-B 数据构造与 ADS-C 观测形态相一致的稀疏训练样本，使模型在可监督条件下学习长缺失区间的恢复规律。对于经稀疏化处理后形成的带有锚点约束的轨迹样本，模型需要恢复缺失区间内的完整轨迹状态，并最终在 ADS-C 数据上验证其分钟级轨迹恢复能力。

设单个样本的时间长度为 T ，记观测掩码为 $\{m_t\}_{t=1}^T$ ，其中 $m_t = 1$ 表示第 t 个时刻存在观测锚点， $m_t = 0$ 表示该时刻轨迹缺失。由此，可将样本中的时间索引划分为观测集合与缺失集合，分别表示为

$$\Omega_{obs} = \{t|m_t = 1\}, \Omega_{miss} = \{t|m_t = 0\}.$$

前者主要用于约束已知边界附近的重建一致性，后者对应轨迹恢复任务的核心目标区域。

设模型在时刻 t 的预测轨迹状态为 $\hat{\mathbf{p}}_t = [\hat{x}_t, \hat{y}_t, \hat{z}_t]$ ，对应的真实轨迹状态为 $\mathbf{p}_t = [x_t, y_t, z_t]$ ，其中， x_t 、 y_t 和 z_t 分别表示第 t 个时刻的经度、纬度和高度，且高度 z_t 的单位为米。本文的目标是在已知稀疏锚点约束的条件下，使恢复轨迹在缺失区间内尽可能接近真实轨迹，并同时兼顾高度恢复的边界稳定性与复杂片段下的重建质量。

基于上述任务定义，本文采用多目标联合优化方式训练轨迹恢复模型，其总体损失函数定义为

$$\mathcal{L} = \mathcal{L}_{rec} + \lambda_{aux} \mathcal{L}_{aux},$$

其中， $\mathcal{L}_{rec}$ 表示基础重建损失，用于约束模型输出与真实轨迹之间的整体偏差； $\mathcal{L}_{aux}$ 表示与高度边界约束及风险片段相关的附加损失项； λ_{aux} 为相应的权重系数，用于平衡附加约束项在总体优化目标中的作用。

考虑到观测锚点区间与缺失区间在任务中的作用并不相同，本文对基础重建损失采用分区域加权形式，即分别对观测时刻和缺失时刻的重建误差进行加权求和。具体定义为

$$\mathcal{L}_{rec} = \lambda_{obs} \sum_{t \in \Omega_{obs}} l(\hat{\mathbf{p}}_t, \mathbf{p}_t) + \lambda_{miss} \sum_{t \in \Omega_{miss}} l(\hat{\mathbf{p}}_t, \mathbf{p}_t),$$

其中， λ_{obs} 和 λ_{miss} 分别表示观测区间和缺失区间的损失权重， $l(\cdot, \cdot)$ 表示逐时刻回归误差函数。本文采用逐维度的平滑 L_1 型误差，其表达式为

$$l(\hat{\mathbf{p}}_t, \mathbf{p}_t) = \sum_{k \in \{x, y, z\}} |\hat{p}_{t,k} - p_{t,k}|,$$

其中， $\hat{p}_{t,k}$ 和 $p_{t,k}$ 分别表示预测状态与真实状态在第 k 个维度上的取值。对应地，上式也可写为


$$l(\hat{\mathbf{p}}_t, \mathbf{p}_t) = |\hat{x}_t - x_t| + |\hat{y}_t - y_t| + |\hat{z}_t - z_t|.$$

在具体实现中，本文设置

$$\lambda_{obs} = 1.0, \lambda_{miss} = 2.0.$$

3.3 具体方案设计

3.3.1 整体框架



3.3.1 ADS-B 数据预处理

在跨洋航班轨迹恢复任务中，直接使用 ADS-C 数据训练面临稀疏且不规则、缺失区间缺乏连续真值的问题。为此，本文利用高分辨率、连续性更好的 ADS-B 数据构建训练样本，通过分钟聚合与稀疏采样模拟 ADS-C 观测形式，在缺失区间两侧保留锚点信息，使模型学习重点转向稀疏轨迹恢复。由于 ADS-B 与 ADS-C 反映相同飞行器运动状态，其底层动力学一致，ADS-B 学到的连续性和边界规律可迁移到 ADS-C 稀疏场景。相比直接使用 ADS-C，基于 ADS-B 构建的训练集样本量大、航段覆盖广、可控性强，有助于降低噪声、提升训练效率和泛化能力，并通过测试集与真实回放验证了恢复精度与形态稳定性。

考虑到本文面向的真实恢复场景主要发生在跨洋飞行阶段，而跨洋 ADS-C 报文的稀疏观测通常对应巡航过程，因此训练样本也应尽可能与该目标场景在飞行阶段和运动特性上保持一致。在收集到来自 Opensky 的 4,868 次航班的 ADS-B 原始数据集后，首先对于同一分钟内的多条 ADS-B 记录中的纬度、高度和速度进行均值聚合，之后再依据垂直速度、速度变化率、航向变化率及持续时长对轨迹进行巡航段筛选。设

$$v_t^{alt} = \frac{alt_t - alt_{t-1}}{\Delta t}, \Delta v_t = \frac{|speed_t - speed_{t-1}|}{\Delta t}, \Delta \theta_t = \frac{|\theta_t - \theta_{t-1}|}{\Delta t},$$

则当轨迹满足

$$|v_t^{alt}| \leq 300, \Delta v_t \leq 30, \Delta \theta_t \leq 5$$

且连续满足上述条件的时长不少于 40 分钟时，该区段被保留为候选巡航样本。

预处理后共保留 1,456 次航班，共 116,367 条航迹数据，时间为 2024-05-01 到 2024-12-

01，并按照 8：1：1 的比例划分训练集、验证集和测试集。样本结构如下表：

ICAO 飞机标识	Flightid 航班记录标识	时间	经度 (°)	纬度 (°)	高度 (m)	速度	航向角
0100a7	MSR509	2024-11-02 13:10:00	29.572960 805084744	35.0691133 38694855	11887.2	0.51444 4	180.0
0100a7	MSR509	2024-11-02 13:11:00	29.572960 805084744	35.0691133 38694855	11887.2	0.51444 4	180.0
0100a7	MSR509	2024-11-02 13:12:00	29.572960 805084744	35.0691133 38694855	11887.2	0.51444 4	180.0
...	...	...	...	...	...	...	...
0100a7	MSR509	2024-11-02 20:48:00	21.209318 62006753	103.986031 13347833	12496.8	247.549 399806 33296	85.1495 780888 8374

3.3.2 训练样本构造

为更直观地展示两类数据在空间覆盖范围和观测场景上的差异，图 X 选取了部分具有代表性的航班，并以其起降机场之间的航线连线进行可视化表达。其中，红色表示 ADS-C 航线样本，共对应 236 架次航班，主要分布于跨洋及长航程航线；蓝色表示 ADS-B 航线样本，共对应 300 架次航班，主要集中在地面接收设施较完善的陆地区域。两类数据在空间覆盖和观测场景上的差异，反映出 ADS-C 更适用于跨洋稀疏监视场景，而 ADS-B 更适合作为高频连续训练数据来源。




图 X 全球 ADS-B\ADS-C 航班分布特征

本论文共收集筛选了来自 Opensky 网站的 1200 个航班的 ADS-C 数据，时间范围为 2024-12-26 到 2024-12-31，并将同分钟内相邻锚点的数据进行聚合，最终收集到 8,960 个可用锚点。ADS-C 数据同一航班中锚点数量及相邻锚点间隔统计如下图 X，可以看出，相邻锚点之间的时间间隔整体表现出“短间隔占主导、长间隔长尾延伸”的分布形态，且 ADS-C 轨迹呈现出明显的稀疏性特征。这说明 ADS-C 轨迹恢复面临的不仅是低频观测问题，还具有显著的不规则采样和长缺失区间特征。




图 X ADS-C 数据同一航班中锚点数量及相邻锚点间隔统计

考虑到跨洋航班长缺失轨迹恢复任务中，不同训练样本在恢复难度及与目标场景分布一致性方面存在明显差异，若直接采用统一随机采样方式进行训练，模型容易偏向高频、低难度样本，从而削弱对长缺失段、复杂边界段及真实稀疏长尾形态的学习能力。为此，本文在基于 ADS-B 构造训练样本的基础上，设计了面向真实 ADS-C 缺失统计特征的分层样本组织与渐进式课程采样策略。

根据真实 ADS-C 轨迹数据的统计特征，将训练数据分为不同的三个阶段。Stage1 主要对应短缺失、低缺失率且边界条件稳定的样本，用于学习基本的轨迹连续性与边界衔接关

系；Stage2 包含中等跨度和较高恢复难度的样本，用于增强模型对较长时间间隔状态演化的表征能力；Stage3 则依据真实 ADS-C 分布进行采样，使训练样本形态尽可能接近目标应用场景。该策略有助于兼顾训练稳定性与真实场景适应性。具体分布设置如下表 X

表 X ADS-B 训练数据不同阶段的特征

Stage	Gap 区间定义（分钟）	缺失比例	主要作用
Stage1	1-3, 3-6, 6-10	0.08, 0.12, 0.16	先学稳定边界衔接与短缺失恢复，降低训练初期发散风险
Stage2	10-20, 20-30, 30-45	0.22, 0.30, 0.40	强化中长缺失恢复能力，补足仅短缺失训练的能力缺口
Stage3	采用 ADS-C 数据特征采样	由经验采样自然决定	与真实 ADS-C 稀疏形态对齐，用于最终收敛与真实泛化

图 X 显示了 stage1、stage2 和 stage3 的锚点数分布，stage1 的锚点数量整体较高且分布范围较宽，说明该阶段样本保留了更充分的观测上下文信息，边界条件相对稳定，恢复难度较低；stage2 的锚点分布相较 stage1 明显左移，表明其在降低可观测上下文规模的同时，引入了更强的稀疏性；stage3 的锚点数量则集中于更低区间，说明其观测信息最为有限，稀疏程度最高，与真实 ADS-C 场景下已知报文稀少的特征更为一致。




图 X 单个航迹中锚点数量的分布

图 X 进一步给出了不同阶段样本的连续缺失长度归一化分布。stage1 的概率质量主要集中于短 gap 区间，随着缺失长度增加，分布迅速衰减，表明其主要承担基础连续性学习和短缺失恢复能力建立的作用；stage2 在中等缺失区间的占比明显提升，连续缺失长度覆盖范围显著扩展，反映出该阶段已开始系统引入中长缺失样本，用于增强模型对较大时间跨度状态演化的表征能力；stage3 则呈现出更明显的长尾特性，在较大 gap 区间仍具有非忽略概率，其整体形态更贴近真实 ADS-C 的经验间隔分布。





图 2 缺失长度分布

综合两类统计结果可以认为，所构造的分层样本形成了由易到难、并逐步向目标场景分布对齐的结构化递进关系，从而为后续课程采样策略的设计提供了数据分布层面的支撑。

3.3.3 基于 Gap-aware 的双向 LSTM 三维数据恢复主干



为恢复 ADS-C 稀疏观测条件下缺失区间内的分钟级轨迹，本文构建了由前向预测模块、后向预测模块和双向融合模块组成的主干恢复结构。设长度为 T 的轨迹样本在时刻 t 的真实状态为

$$\mathbf{p}_t = [x_t, y_t, z_t] \in \mathbb{R}^3,$$

其中 x_t 、 y_t 和 z_t 分别表示经度、纬度和高度；其对应的稀疏观测输入记为

$$\mathbf{q}_t = [x_t^{obs}, y_t^{obs}, z_t^{obs}] \in \mathbb{R}^3.$$

观测掩码记为 $m_t \in \{0,1\}$ ，其中 $m_t = 1$ 表示该时刻存在观测锚点， $m_t = 0$ 表示该时刻属于缺失区间。

进一步地，定义当前时刻到左侧最近锚点和右侧最近锚点的时间距离分别为 d_t^L 和 d_t^R 。由于单独的时间距离只能描述当前时刻距离某一侧锚点的绝对间隔，而无法唯一表征该点在整个缺失区间中的归一化位置。为补充缺失区间的结构信息与局部动态信息，引入辅助特征向量

$$\mathbf{s}_t = [r_t, v_t, \Delta v_t, \omega_t] \in \mathbb{R}^4,$$

其中

$$r_t = \frac{d_t^L}{d_t^L + d_t^R + \varepsilon}$$

表示当前时刻在整个缺失区间内部的相对位置； v_t 表示局部垂直速度， Δv_t 表示局部速度变化量， ω_t 表示局部转向率。

3.3.3.1 前向预测模块

前向预测模块沿时间正方向递推，核心目标是在时刻 t 基于过去状态、当前稀疏观测以及左侧边界信息，预测当前位置的候选轨迹状态。为此，定义前向分支在时刻 t 的输入为

$$\mathbf{u}_t^f = [\mathbf{r}_{t-1}^f, \mathbf{q}_t, m_t, d_t^L, \mathbf{s}_t],$$

其中 $\mathbf{r}_t^f \in \mathbb{R}^3$ 表示来自前一时刻的反馈状态。这里的反馈并不直接等于当前时刻真值，而是来源于上一时刻的预测结果，或在教师强制条件下来源于上一时刻真实状态，从而保证模型在当前时刻的恢复仍然是递推生成式的。

由于 $\mathbf{u}_t^f$ 中同时包含轨迹坐标、时间距离和辅助特征，不同分量之间量纲差异较大，因此首先通过输入编码函数 $\Psi(\cdot)$ 将其映射到统一隐藏空间：

$$\tilde{\mathbf{u}}_t^f = \Psi(\mathbf{u}_t^f).$$

在实现上， $\Psi(\cdot)$ 由线性层、层归一化和非线性激活函数组成，用于获得更稳定的时序输入表示。

为了显式反映时间间隔对历史信息有效性的影响，本文在前向递推中引入时间间隔相关的状态衰减机制。设前向分支在时刻 $t-1$ 的隐藏状态和记忆状态分别为 $\mathbf{h}_{t-1}^f$ 和 $\mathbf{c}_{t-1}^f$ ，则首先根据时间距离 d_t^L 计算衰减系数：

$$\gamma_t^f = \exp(-\text{ReLU}(\mathbf{W}_\gamma^f d_t^L + \mathbf{b}_\gamma^f)),$$

其中 $\mathbf{W}_\gamma^f$ 和 $\mathbf{b}_\gamma^f$ 为可学习参数。随后对前一时刻状态进行衰减：

$$\tilde{\mathbf{h}}_{t-1}^f = \gamma_t^f \odot \mathbf{h}_{t-1}^f, \tilde{\mathbf{c}}_{t-1}^f = \gamma_t^f \odot \mathbf{c}_{t-1}^f.$$

将衰减后的状态送入 LSTM 单元，可得

$$\mathbf{h}_t^f, \mathbf{c}_t^f = \text{LSTMCell}(\tilde{\mathbf{u}}_t^f, \tilde{\mathbf{h}}_{t-1}^f, \tilde{\mathbf{c}}_{t-1}^f).$$

最后，通过线性输出头将隐藏状态映射为三维候选恢复结果：

$$\boldsymbol{\mu}_t^f = \mathbf{W}_o^f \mathbf{h}_t^f + \mathbf{b}_o^f, \boldsymbol{\mu}_t^f \in \mathbb{R}^3.$$

其中 $\boldsymbol{\mu}_t^f$ 表示由左侧上下文推断得到的前向候选轨迹状态。

由于前向与后向分支均采用递推式状态反馈机制，若训练阶段始终使用模型自身预测作为下一步输入，则早期预测误差会沿时间方向持续传播，并在长缺失区间内累积放大。为缓解这一问题，本文在训练过程中引入教师强制策略，以一定概率使用相邻时刻真实状态替代模型预测作为反馈输入，从而提高训练初期的稳定性并加速模型收敛。

$$\mathbf{r}_{t+1}^f = \begin{cases} \mathbf{p}_t, & \text{with probability } \eta, \\ \boldsymbol{\mu}_t^f, & \text{with probability } 1 - \eta, \end{cases}$$

其中 η 表示教师强制比例。在具体实现中，教师强制比例初始设置为 0.8，并按轮次以衰减系数 0.95 逐步减小。

3.3.3.2 后向预测模块

后向预测模块与前向模块结构对称，但沿时间反方向递推，其目标是在时刻 t 基于未来状态、当前稀疏观测以及右侧边界信息，生成另一组候选轨迹状态。定义后向分支输入为

$$\mathbf{u}_t^b = [\mathbf{r}_{t+1}^b, \mathbf{q}_t, m_t, d_t^R, \mathbf{s}_t],$$

其中 $\mathbf{r}_t^b \in \mathbb{R}^3$ 表示来自后一时刻的反馈状态。

类似地，首先通过输入编码函数得到隐藏表示：

$$\tilde{\mathbf{u}}_t^b = \Psi(\mathbf{u}_t^b).$$

然后根据右侧时间距离 d_t^R 计算后向分支的状态衰减系数：

$$\gamma_t^b = \exp(-\text{ReLU}(\mathbf{W}_\gamma^b d_t^R + \mathbf{b}_\gamma^b)),$$

并对后一时刻状态 $\mathbf{h}_{t+1}^b, \mathbf{c}_{t+1}^b$ 进行衰减：

$$\tilde{\mathbf{h}}_{t+1}^b = \gamma_t^b \odot \mathbf{h}_{t+1}^b, \tilde{\mathbf{c}}_{t+1}^b = \gamma_t^b \odot \mathbf{c}_{t+1}^b.$$

于是，后向递推过程表示为

$$\mathbf{h}_t^b, \mathbf{c}_t^b = \text{LSTMCell}(\tilde{\mathbf{u}}_t^b, \tilde{\mathbf{h}}_{t+1}^b, \tilde{\mathbf{c}}_{t+1}^b).$$

随后，通过输出映射得到后向候选恢复结果：

$$\boldsymbol{\mu}_t^b = \mathbf{W}_o^b \mathbf{h}_t^b + \mathbf{b}_o^b, \boldsymbol{\mu}_t^b \in \mathbb{R}^3.$$

其中 $\boldsymbol{\mu}_t^b$ 表示由右侧上下文推断得到的候选轨迹状态。

训练时，后向分支的反馈状态同样采用教师强制机制：

$$\mathbf{r}_{t-1}^b = \begin{cases} \mathbf{p}_t, & \text{with probability } \eta, \\ \boldsymbol{\mu}_t^b, & \text{with probability } 1 - \eta. \end{cases}$$

由于前向分支主要依赖左侧边界信息，后向分支主要依赖右侧边界信息，因此二者在缺失区间内部具有天然互补性。特别是在中长缺失区间内，单侧上下文往往不足以支撑稳定恢复，而双向结构能够同时引入两侧边界约束，提高缺口内部恢复的可靠性。

3.3.3.3 双向融合模块

在获得前向候选输出 $\boldsymbol{\mu}_t^f$ 与后向候选输出 $\boldsymbol{\mu}_t^b$ 后，需要进一步将两个方向的恢复结果融合为当前时刻的主干预测结果。由于缺失区间内不同位置受到左右边界锚点的约束程度并不相同，若直接采用简单平均或固定比例加权，则难以根据当前时刻的结构位置动态调整前向信息与后向信息的贡献。因此，本文设计一种基于位置结构特征的自适应双向融合模块，用于学习不同时间位置下前向候选结果与后向候选结果的相对可靠性。

对于第 t 个时刻，定义融合输入为

$$\mathbf{g}_t = [\boldsymbol{\mu}_t^f; \boldsymbol{\mu}_t^b; d_t^L; d_t^R; r_t; m_t],$$

其中， $\boldsymbol{\mu}_t^f$ 和 $\boldsymbol{\mu}_t^b$ 分别表示前向预测模块和后向预测模块输出的候选恢复状态； d_t^L 和 d_t^R 分别表示当前时刻与左侧锚点、右侧锚点之间的绝对时间距离； r_t 表示当前时刻在缺失区间内的归一化相对位置； m_t 为观测掩码，用于标识当前时刻为观测点还是缺失点。上述特征共同刻画了当前时刻的候选恢复状态、边界距离关系以及观测可用性。

为了根据这些信息生成自适应融合权重，本文采用一个双层感知机作为权重生成器。首先，双层感知机的第一层对融合输入进行非线性特征变换：

$$\mathbf{h}_t = \sigma(\mathbf{W}_1 \mathbf{g}_t + \mathbf{b}_1),$$

其中， $\mathbf{W}_1$ 和 $\mathbf{b}_1$ 为第一层可学习参数， $\sigma(\cdot)$ 表示非线性激活函数。该过程用于从前向后候选状态、边界距离和掩码信息中提取用于判断融合关系的中间特征。

随后，第二层将隐藏特征映射为两个方向的未归一化融合打分：

$$\boldsymbol{\alpha}_t = \mathbf{W}_2 \mathbf{h}_t + \mathbf{b}_2, \boldsymbol{\alpha}_t = [\alpha_t^f, \alpha_t^b] \in \mathbb{R}^2,$$

其中， α_t^f 和 α_t^b 分别表示前向候选输出与后向候选输出在当前时刻的相对可信度打分。需要指出的是， $\boldsymbol{\alpha}_t$ 并不是最终融合权重，而是由模型学习得到的中间评分。为了使两个方向的权重具有可比较性，并满足非负性与归一化约束，进一步采用 softmax 函数得到最终融合权重：

$$[w_t^f, w_t^b] = \text{softmax}(\boldsymbol{\alpha}_t), w_t^f + w_t^b = 1.$$

最终，当前时刻的主干恢复结果表示为

$$\hat{\mathbf{p}}_t^{\text{main}} = w_t^f \boldsymbol{\mu}_t^f + w_t^b \boldsymbol{\mu}_t^b.$$

与单向恢复模型相比，该结构能够同时利用缺失区间左右两侧的上下文信息，并通过学习型融合机制根据当前恢复位置动态调整双向信息贡献，从而增强恢复轨迹在边界附近的连续性，并降低中长缺失区间内单一方向预测误差累积带来的影响。因此更适合 ADS-C 稀疏观测场景下的中长缺失轨迹恢复任务。

3.3.4 高度维度处理分支

尽管双向主干与融合模块能够给出三维主恢复结果

$$\hat{\mathbf{p}}_t^{\text{main}} = [\hat{x}_t^{\text{main}}, \hat{y}_t^{\text{main}}, \hat{z}_t^{\text{main}}],$$

但三维状态中不同分量的恢复难点并不一致。对于经纬度而言，主干输出通常已能够较好地刻画缺失区间内的轨迹走向与位置连续性；而对于高度而言，其变化不仅受局部时序信息影响，还更强地依赖缺失区间两端锚点所确定的整体趋势。特别是在长缺失场景下，若仍将高度与平面位置完全等同处理，仅依赖主干网络统一回归，则难以充分表达高度对边界条件和整体变化框架的特殊依赖，导致高度恢复误差相对较大。

基于此，本文不将高度分支设计为独立于主干之外的另一套完整恢复网络，而是在双向主干输出的高度通道基础上进一步进行专项处理。具体而言，主干模块首先完成三维轨迹的统一粗恢复，其中经纬度结果可直接作为平面位置输出，而高度通道则作为后续精化的基础输入。在此基础上，本文将高度恢复分解为两个层次：首先利用边界条件驱动主趋势恢复，以确定高度变化的整体框架；随后通过风险感知下的残差细化，对主趋势未能表达的局部非线性变化进行补，从而将高度恢复被转化为一个受约束的分层建模问题，从而提高长缺失区间内恢复结果的稳定性与可解释性。

3.3.4.1 建模高度主趋势

记当前时刻左右边界锚点高度分别为 z^L, z^R ，前文已定义缺失区间内部相对位置

$$r_t = \frac{d_t^L}{d_t^L + d_t^R + \varepsilon}.$$

其中， d_t^L 和 d_t^R 分别表示当前时刻到左、右边界锚点的时间距离， ε 为防止分母为零的微小常数。该相对位置量满足 $r_t \in (0,1)$ ，能够刻画当前时刻在整个缺失区间中的归一化位置：当 t 靠近左边界时， r_t 较小；当 t 靠近右边界时， r_t 较大。因此， r_t 为后续基于边界条件构造主趋势提供了统一的位置参数。

在此基础上，本节首先构造由边界条件决定的线性高度基线

$$z_t^{base} = z^L + r_t(z^R - z^L).$$

该式本质上是沿缺失区间在左右边界高度之间进行线性插值，从而给出一个由锚点完全决定的基准趋势，用于描述在不考虑局部波动时，确定该区间的基本走向。由于该基线仅依赖 z^L 、 z^R 和相对位置 r_t ，当位置接近左边界或右边界时，其取值分别受相应锚点约束。然而，真实飞行中的高度变化通常并非严格线性。即使在巡航阶段，高度序列仍可能存在缓慢爬升、小幅下降或局部波动。因此，若仅使用线性基线，则容易造成整体趋势过于僵硬，难以拟合真实高度走势。为此，本文进一步利用主干融合输出中的高度 $\hat{z}_t^{fusion}$ 构造主趋势偏移项。具体地，将该高度通过有界映射变换为

$$\delta_t^{main} = R_{main} \tanh(\hat{z}_t^{fusion}),$$

其中， R_{main} 表示主趋势偏移的幅值上界。由于双曲正切函数的输出范围为 $(-1,1)$ ，因此 δ_t^{main} 被限制在 $(-R_{main}, R_{main})$ 内，从而避免主趋势偏移过大而脱离边界所决定的整体框架，同时允许模型在基线趋势基础上进行适度修正。

于是，主趋势高度定义为

$$z_t^{main} = z_t^{base} + \delta_t^{main}.$$

其中 z_t^{base} 保证了主趋势始终处于合理的边界框架内， δ_t^{main} 使模型能够根据主干融合特征适应不同缺口内部的实际变化模式。由此，主趋势分支学习的不是完整高度值本身，而是一个以边界条件为基准、幅值受控的趋势修正量。

3.3.4.2 提取高度残差细化信息

尽管主趋势高度 z_t^{main} 已能够较好地保证左右边界一致性，并刻画缺失区间内的整体变化趋势，但真实飞行过程中的高度演化通常仍包含更细粒度的局部非线性变化。例如，在总体较为平稳的背景下，中段仍可能出现轻微缓升、局部下沉，或者边界附近存在小幅曲率变化。这类变化通常难以仅依靠低频主趋势表示。基于此，本文在主趋势高度基础上进一步引入高度残差细化分支，用于学习主趋势尚未解释的局部偏差，从而提高高度恢复结果对局部细节的表征能力。

设高度细化分支在时刻 t 的主上下文表示为

$$c_t = [\hat{z}_t^{main}, z_t^{main}],$$

其中, $\hat{z}_t^{main}$ 为主干恢复得到的高度粗结果, 反映双向主干在统一三维恢复框架下对当前位置高度的初始估计; z_t^{main} 为由边界条件驱动构造得到的主趋势高度, 用于提供显式的趋势先验。二者分别对应主干恢复语义和边界约束趋势, 共同构成高度细化阶段的基础输入。

进一步地, 定义边界辅助特征为

$$b_t = [m_t, d_t^L, d_t^R, r_t, z^L, z^R, z^R - z^L, z_t^{base}, s_t],$$

其中, m_t 表示当前时刻是否为观测锚点; d_t^L 和 d_t^R 分别表示当前时刻到左、右边界锚点的时间距离; r_t 表示当前位置在缺失区间内部的相对位置; z^L 和 z^R 分别表示左右边界锚点高度; $z^R - z^L$ 刻画整个缺失区间的高度跨度; z_t^{base} 表示由边界条件构造的线性高度基线; s_t 为前文定义的辅助特征向量, 用于补充局部动态背景信息。这里, c_t 主要表征当前位置的恢复状态, 而 b_t 则进一步补充与边界条件、缺口结构及局部动态相关的显式信息。

基于 c_t 与 b_t , 本文将高度残差细化过程划分为三个连续步骤: 注意力加权聚合、局部残差解码和全局一致性细化。

(1) 注意力加权聚合

首先, 对缺失区间内各时刻进行位置重要性建模。由于不同位置在局部残差恢复中的作用并不一致, 模型有必要对其信息贡献进行区分。一般而言, 边界附近的位置与连续性保持和边界衔接更为密切, 而区间中部则更可能承载局部波动信息。基于此, 将 c_t 与 b_t 拼接后输入注意力打分网络, 计算当前位置的注意力分数:

$$s_t^{att} = w_{att}^\top \phi(W_{att}[c_t, b_t] + b_{att}^{(1)}) + b_{att}^{(2)},$$

其中, W_{att} 、 w_{att} 、 $b_{att}^{(1)}$ 和 $b_{att}^{(2)}$ 为可学习参数, $\phi(\cdot)$ 表示非线性激活函数。该分数用于衡量当前位置在整段高度细化过程中的相对重要性。

随后, 对整段缺失区间上的打分结果进行 softmax 归一化, 得到时序注意力权重

$$\alpha_t = \frac{\exp(s_t^{att})}{\sum_{j=1}^T \exp(s_j^{att})}.$$

基于该权重, 定义注意力调制后的当前位置表示为

$$\tilde{c}_t = \alpha_t c_t,$$

并进一步对整段序列进行聚合, 得到全局上下文向量

$$\bar{c} = \sum_{t=1}^T \tilde{c}_t.$$

其中, $\tilde{c}_t$ 表示经过位置重要性加权后的当前位置表示, 主要反映当前时刻在细化阶段的局部语义; $\bar{c}$ 表示对整段缺失区间进行聚合后得到的全局上下文, 用于刻画当前样本在高度变化上的整体背景。因此, 这一步的作用并不是直接生成残差, 而是先从整段序列中提取与局部高度修正更相关的信息, 为后续解码提供基础。

(2) 局部残差解码

在得到位置加权后的局部表示 $\tilde{c}_t$ 和整段全局上下文 $\bar{c}$ 后，本文将其与边界辅助特征 b_t 联合输入局部残差解码网络，生成当前位置的细化潜变量。具体表示为

$$u_t^{res} = [\tilde{c}_t, \bar{c}, b_t],$$

$$l_t = W_{dec}^{(2)} \phi \left(W_{dec}^{(1)} u_t^{res} + b_{dec}^{(1)} \right) + b_{dec}^{(2)}.$$

其中， u_t^{res} 融合了三类信息：一是注意力调制后的当前位置表示 $\tilde{c}_t$ ，用于反映当前时刻的局部恢复语义；二是全局上下文 $\bar{c}$ ，用于提供整段缺失区间的整体趋势背景；三是边界辅助特征 b_t ，用于保留显式的缺口结构和边界条件。由此得到的潜变量 l_t 可理解为当前位置在主趋势基础上可能存在的局部高度偏差模式的中间表示。它并不是最终残差本身，而是对局部细化信息进行压缩和编码后的潜在状态。

(3) 全局一致性细化

由于局部残差并不是彼此独立的，不同时刻的细化结果在整段缺失区间内部应保持一定的一致性与协调性。若仅依赖逐时刻解码得到的潜变量 l_t ，容易导致局部细化结果在时序上缺乏协调，进而产生不必要的振荡。为此，本文进一步将潜变量序列 $\{l_t\}_{t=1}^T$ 输入轻量级时序细化模块，对其进行全局一致性建模：

$$h_t^{res} = \text{Refine}(l_{1:T})_t,$$

其中， $\text{Refine}(\cdot)$ 表示轻量级全局一致性细化映射， h_t^{res} 表示经过时序细化后的优化潜在表示。该步骤的作用在于显式建模相邻位置之间的联系，使细化残差在整个缺失区间内部具有更好的连续性和协调性，从而避免不同位置独立生成修正量时产生的局部不一致问题。

在此基础上，通过线性输出层得到候选高度残差：

$$\Delta z_t^{cand} = w_{res}^T h_t^{res} + b_{res}.$$

综上，高度残差细化分支可统一表示为

$$\Delta z_t^{cand} = G_{res}(c_{1:T}, b_{1:T})_t,$$

其中， $G_{res}(\cdot)$ 由“注意力加权聚合—局部残差解码—全局一致性细化—线性输出”四个部分共同组成。需要指出的是， Δz_t^{cand} 的建模目标并不是恢复整段高度主趋势，而仅用于拟合主趋势高度 z_t^{main} 尚未解释的局部偏差。因此，该分支本质上承担的是残差补偿而非整体生成功能。通过将高度恢复拆解为主趋势恢复与局部残差补偿两个层次，模型能够先利用边界条件确定整体框架，再在此基础上学习局部非线性细节，从而有效降低学习难度，并提高高度恢复过程的稳定性与可解释性。

3.3.4.3 风险约束残差处理

在得到候选高度残差 Δz_t^{cand} 后，若直接将其无约束地叠加到主趋势高度 z_t^{main} 上，虽然可能提高局部拟合能力，但也更容易在复杂缺失片段中引入过强修正。尤其在边界附近或高风险片段中，这种无约束残差可能影响主趋势所提供的整体稳定框架，从而削弱恢复结果在边界衔接与整体平稳性方面的表现。基于此，本文在高度分支内部进一步引入风险约束下的

残差注入机制，使局部细化始终在可控范围内进行。

设样本 i 所属缺失片段对应的风险控制系数为 $\gamma_i \in [0,1]$ ，残差幅值上界为 $R_i^{res} > 0$ 。其中， γ_i 用于调节候选残差实际注入主趋势时的强度， R_i^{res} 用于限制最终残差修正的幅值范围。本方案根据缺失片段的两个结构属性进行风险划分：其一为片段长度分桶（短片段 ≤ 15 min，中等片段 15–30 min，长片段 > 30 min），其二为边界锚点模式（双边锚点、非对称锚点、稀疏上下文）。两个维度组合后按预设优先级规则进行匹配，将每个缺失片段划分为高风险、中风险或低风险三类，并分别赋予对应的残差注入强度 γ_i 和残差幅值上界 R_i^{res} 。表 X 给出了不同风险等级对应的典型参数配置。一般而言，风险等级越高，所对应的 γ_i 与 R_i^{res} 越小，以限制局部残差对整体趋势的扰动；风险等级较低时，则允许更充分的残差注入，以保留必要的局部细化能力。

风险等级	典型结构特征	γ_i	$R_i^{res}(ft)$
低风险	长片段、非对称锚点（单侧锚点可靠）	0.85	900
中风险	中等/长片段、双边锚点	0.40–0.55	450–550
高风险	短片段（各类锚点模式）；中等片段且锚点稀疏或非对称	0.15–0.30	200–350

从表中可以看出，风险等级的划分逻辑与直觉一致：短片段由于观测信息少、不确定性高，无论锚点模式如何均被归为高风险；中等片段在锚点稀疏或非对称时不确定性上升，同样归为高风险；只有当片段较长且锚点模式较为可靠时，才赋予较低的 γ_i 惩罚和 R_i^{res} 容限，以允许模型进行更充分的局部细化。

在确定片段级风险参数后，首先对候选残差进行强度门控，定义门控后的残差为

$$\widetilde{\Delta z}_t = \gamma_i \Delta z_t^{cand}.$$

该式表明，风险控制系数 γ_i 直接决定了候选残差的实际注入强度。当片段风险较高时，较小的 γ_i 会减弱候选残差对主趋势的影响；当片段风险较低时， γ_i 较接近 1，则允许模型更充分地利用候选残差补充局部细节。因此， γ_i 本质上起到残差强度调制器的作用，用于控制局部细化对整体趋势的干扰程度。

在此基础上，为进一步避免门控后的残差幅值过大，本文采用有界映射将其压缩到区间 $[-R_i^{res}, R_i^{res}]$ 内：

$$\Delta z_t^{res} = R_i^{res} \tanh\left(\frac{\widetilde{\Delta z}_t}{R_i^{res} + \varepsilon}\right).$$

其中，双曲正切函数保证输出始终处于有界范围内，而 R_i^{res} 直接控制允许的最大残差修正幅值。通过这一映射，即使候选残差本身较大，其最终注入主趋势时也会被限制在与当前风险等级相匹配的可控范围内。由此，残差分支既能够保留必要的局部修正能力，又不会因幅值失控而破坏主趋势所提供的整体框架。

最终高度分支输出的最终细化结果表示为

$$\hat{z}_t = z_t^{main} + \Delta z_t^{res}.$$

将主趋势项代入后，可得最终高度输出的完整形式：

$$\hat{z}_t = z_t^{base} + R_{main} \tanh(\hat{z}_t^{fusion}) + R_i^{res} \tanh\left(\frac{\gamma_i \Delta z_t^{cand}}{R_i^{res} + \varepsilon}\right).$$

从该表达式可以看出，最终高度由三部分构成。第一部分 z_t^{base} 表示由边界条件决定的线性基线趋势，用于提供整体变化框架；第二部分 $R_{main} \tanh(\hat{z}_t^{fusion})$ 表示在基线趋势上的受限主趋势偏移，用于补充低频整体变化；第三部分则表示经风险约束后注入的局部残差修正，用于描述主趋势尚未解释的细粒度变化。三者分别对应“边界基线—主趋势修正—局部细化”三个层次，其中 γ_i 与 R_i^{res} 共同保证局部修正始终受控，不会破坏主趋势恢复的整体稳定性。

通过在高度分支内部将局部残差建模为受风险约束的修正，使其与边界主趋势协同完成恢复任务。通过这一机制，模型既能够保留主趋势层面的边界连续性和整体合理性，又能够在可控范围内引入局部非线性细节，从而提高复杂缺失场景下高度恢复结果的稳定性与可解释性。

3.3.5 参数学习与更新策略

在前向预测模块、后向预测模块和双向融合模块共同作用下，模型首先得到主干恢复结果 $\hat{\mathbf{p}}_t^{main}$ ，并在后续高度处理分支中进一步得到最终恢复结果 $\hat{\mathbf{p}}_t$ 。基于前文定义的分区域重建损失与附加约束项，本文的总体优化目标写为

$$L = L_{rec} + \lambda_{aux} L_{aux},$$

其中

$$L_{rec} = \lambda_{obs} \sum_{t \in \Omega_{obs}} l(\hat{\mathbf{p}}_t, \mathbf{p}_t) + \lambda_{miss} \sum_{t \in \Omega_{miss}} l(\hat{\mathbf{p}}_t, \mathbf{p}_t).$$

这里， Ω_{obs} 和 Ω_{miss} 分别表示观测时刻集合和缺失时刻集合， λ_{obs} 与 λ_{miss} 分别表示观测区间与缺失区间的损失权重， $l(\cdot, \cdot)$ 表示逐时刻重建误差函数。由于缺失区间是轨迹恢复任务的核心目标区域，因此训练时对缺失区间赋予更高权重，以强化模型对长缺失片段的恢复能力。

记前向预测模块参数为 θ_f ，后向预测模块参数为 θ_b ，融合模块参数为 θ_{fus} ，高度处理分支参数为 θ_h ，则模型全部待学习参数可统一记为

$$\Theta = \{\theta_f, \theta_b, \theta_{fus}, \theta_h\}.$$

训练过程中，通过最小化总体目标函数 L ，对所有参数进行联合端到端优化：

$$\Theta^* = \arg \min_{\Theta} L.$$

在第 k 次迭代中，参数按照梯度下降方式更新为

$$\Theta^{(k+1)} = \Theta^{(k)} - \eta \nabla_{\Theta} L,$$

其中 η 表示学习率， $\nabla_{\Theta} L$ 表示损失函数对全部模型参数的梯度。在具体实现中，前向分支、后向分支、融合模块和高度处理分支并不是分开独立训练的，而是在同一损失约束下共同更新，使得主干时序恢复能力与高度专项修正能力能够协同收敛。

4 实验结果

4.1 数据集组成与实验设置

本文实验所使用的 ADS-B 数据来自 OpenSky 开放平台。对原始数据进行分钟级聚合、重复记录去除及巡航阶段筛选后,构建用于轨迹恢复任务的数据集。其总体规模如表 4-1 所示。原始分钟级聚合数据共包含 452,640 条记录,对应 4,868 架次航班,时间范围为 2024-05-01 00:00:00 UTC 至 2024-12-01 12:03:00 UTC;在此基础上,进一步依据巡航阶段标记进行筛选后,得到 116,367 条巡航阶段记录,对应 1,456 架次航班。该过程保证了训练数据主要来源于运动状态较稳定、适合长缺失恢复建模的巡航阶段。

阶段	行数	航班数
去重后的原始数据	452,640	4,868
符合巡航阶段的数据	116,367	1,456

为适应不同缺失难度和真实应用场景下的稀疏分布特征,本文进一步基于巡航阶段数据构造了三个训练阶段的样本集合,分别对应低缺失率短缺口样本、中等缺失率样本以及贴近真实 ADS-C 稀疏分布的高缺失率样本。各阶段样本统计结果如表 4-2 所示。可以看出,随着阶段由 stage1 向 stage3 递进,平均缺失比例逐步增大,缺口长度中位数和高分位数也明显增加,表明三个阶段在样本恢复难度上呈现由易到难的递进关系。

阶段	行数	平均缺失率	缺口长度中位数(q50)	缺口长度高分位数(q90)
stage1	403,479	0.121	2	6
stage2	403,479	0.330	3	10
stage3	403,479	0.875	9	27

为避免同一航班轨迹同时出现在训练集和评估集中造成信息泄漏,本文采用按航班标识分组的数据切分策略。以唯一的航班标识号为分组单元,在固定随机种子 seed=42 条件下,对样本进行一次性划分,训练集、验证集和测试集比例分别设置为 0.8、0.1 和 0.1。训练集仅用于模型参数学习,课程学习过程中各阶段样本比例调度仅作用于训练集;验证集用于模型选择、早停判断及超参数调整;测试集仅在训练与模型选择全部完成后使用一次,以保证实验评估的公平性和独立性。

训练轮次	stage1	stage2	stage3
epoch 1-6	0.70	0.25	0.05
epoch 7-12	0.20	0.60	0.20
epoch 13-18	0.15	0.35	0.60
epoch 19-24	0.05	0.20	0.75

在训练策略上，本文采用分阶段课程学习方式组织不同难度样本，其采样比例随训练轮次动态调整。具体设置如表 4-3 所示。训练初期以 stage1 为主，使模型优先学习边界衔接与短缺失恢复；中期逐步提高 stage2 比例，以增强对中长缺失的建模能力；后期则提高 stage3 比例，使模型逐步适应与真实 ADS-C 更一致的高缺失率场景。

本研究采用按航班标识进行分组划分的数据切分策略，以避免同一航班轨迹同时出现在实验基于 Ubuntu 22.04.5 LTS (x86_64) 与 Python 3.13.11 环境完成，实际训练在 CPU 设备上进行。模型采用 AdamW 优化器进行训练，训练轮数为 24，batch size 为 32，初始学习率为 0.001，weight decay 设为 0.0001，并通过梯度裁剪 (1.0) 稳定训练过程。训练阶段采用教师强制策略，其初始比例设为 0.8，并以 0.95 的衰减系数随训练过程逐步降低。模型选择基于验证集上的确实段高度 RMSE 指标进行，保存验证性能最优的 checkpoint；当前主线配置未启用额外的早停机制。损失函数采用分区域加权的重建目标与附加约束项联合优化，其中缺失区间赋予更高权重，以强化模型在长缺失片段上的恢复能力。

4.2 课程学习策略有效性

为验证所提出课程学习策略的有效性，本文设计了四组对比实验：Group1 为本文提出的渐进式课程学习策略；Group2 仅采用 stage3 样本进行训练；Group3 对三个阶段样本采用统一随机采样；Group4 采用与本文相反的逆向课程调度方式。实验结果如表 4-4 所示。

不同的学习策略	高度 RMSE	经度 RMSE	纬度 RMSE
Group1_Proposed	53.49	0.5866	1.3682
Group2_OnlyStage3	69.32	0.6028	1.3953
Group3_Uniform	68.16	0.6127	1.4012
Group4_Reverse	68.58	0.5986	1.3954

结果表明，本文提出的课程学习策略在高度恢复指标上具有明显优势。与仅使用 stage3 样本训练相比，本文方法的高度 RMSE 分别下降了 14.81 和 15.83；相较于统一采样与逆向调度方式，也分别取得了更优的高度恢复性能。与此同时，各组在纬度和经度指标上的差异较小，说明课程学习策略的主要收益集中体现在高度维度，尤其是缺失区间内的高度恢复质量提升上。这说明由易到难的样本组织方式更有利于模型逐步掌握边界衔接、长缺失恢复及真实稀疏场景适应能力。

4.3 高度专项处理分支有效性

为验证高度专项处理分支的作用，本文进一步比较了带高度分支和不带高度分支两种设置下的恢复结果，实验结果如表 4-5 所示。

模型	经度 RMSE	纬度 RMSE	高度 RMSE
OurMethod	0.6202	1.4437	53.4887
去掉高度分支的 OurMethod	0.6200	1.4396	70.8736

可以看出，引入高度专项处理分支后，高度的 RMSE 由 70.873637 显著降低至 53.488740，表明该分支能够有效增强模型在缺失区间内的高度恢复能力。与此同时，经纬度误差变化较小，说明该分支的改进主要集中在高度维度，而不会对平面位置恢复产生明显干扰。这与本文方法的设计目标一致，即在保持主干平面恢复能力的基础上，通过边界主趋势建模、局部残差细化及风险约束注入机制，有针对性地改善高度恢复质量。

4.4 基线模型对比试验

为全面评估本文方法的有效性，本文选取 UniLSTM、Kalman Filter、BiLSTM、CNN+LSTM、LSTM+Attention 以及 Transformer 作为对比基线模型，UniLSTM 作为典型的单向循环网络，仅利用历史时序信息进行状态递推，可用于衡量单侧上下文条件下的轨迹恢复能力。Kalman Filter 作为经典状态估计方法，适用于连续动态系统中的平滑跟踪与短时预测，可作为传统轨迹插补与外推方法的代表。BiLSTM 能够同时建模前向与后向时序依赖关系，更适合利用缺失区间两侧边界信息进行中间片段恢复。CNN+LSTM 结合卷积网络的局部模式提取能力与循环网络的时序建模能力，适用于同时刻画轨迹局部变化与长期演化规律。LSTM+Attention 在循环结构基础上引入注意力机制，能够增强模型对关键时刻和重要上下文信息的选择能力，适用于复杂轨迹序列中的依赖关系建模。Transformer 则基于自注意力机制建立全局时序关联，能够较好地捕获长距离依赖信息，可用于评估全局建模方法在长缺失轨迹恢复任务中的表现。

为确保实验的公平性与可复现性，所有对比模型均在统一设置下进行训练与测试。全部方法使用相同的数据来源与固定的数据划分策略，训练集、验证集和测试集比例保持一致。在训练配置上，各神经网络模型采用相同的优化框架，学习率均为 0.001，批大小为 32，以及 24 个训练轮次；同时，模型有相同的网络规模设置，包括 2 层结构和 128 维隐藏单元。所有模型均在相同测试集上、按照一致的评估协议进行比较，因此实验结果可以有效反映模型结构对于相同的恢复任务的效果差异。

通过在缺失区间内统计经纬度与高度的 RMSE 和 MAE 指标评估极限模型的性能，实验结果如表 4-6 所示。

模型	RMSE			MAE		
	经度	纬度	高度	经度	纬度	高度
OurMethod	0.620	1.444	53.489	0.511	1.192	32.119
UniLSTM	0.620	1.440	70.801	0.510	1.189	45.554

模型	RMSE			MAE		
	经度	纬度	高度	经度	纬度	高度
Kalman Filter	5.188	21.822	70.850	3.801	14.506	45.594
BiLSTM	0.620	1.440	70.864	0.510	1.189	45.599
CNN+LSTM	0.620	1.438	70.883	0.511	1.188	45.570
LSTM+Attention	0.619	1.431	71.049	0.510	1.182	45.814
Transformer	0.601	0.524	73.594	0.495	0.408	48.733

表 X 给出了不同模型在缺失区间内部的恢复误差结果。整体来看，各模型在水平位置维度和高度维度上呈现出明显不同的性能分布特征。在水平位置恢复方面，Transformer 在 Gap-Lat RMSE、Gap-Lon RMSE 及对应的 MAE 指标上均取得最优结果，表明基于自注意力机制的全局依赖建模方式在平面位置恢复中具有较强优势。相比之下，UniLSTM、BiLSTM Baseline、CNN+LSTM 和 LSTM+Attention 等常规时序模型之间差异较小，说明简单更换循环结构或引入局部增强模块，并未显著改变该任务中水平位置恢复的性能边界。


与之不同，本文方法在高度维度上表现出显著优势，其中 高度 RMSE 和 高度 MAE 分别达到 53.489 和 32.119，均明显优于所有对比模型。其余深度学习基线在 高度 RMSE 上普遍维持在 70 左右，在 高度 MAE 上则集中在 45-49 之间，说明若仍将高度与水平位置统一建模为同质回归目标，则难以有效处理高度恢复中存在的边界约束和局部非线性变化问题。本文方法通过针对高度维度引入专门的结构化建模策略，将高度恢复由直接绝对值回归转化为受边界条件约束的主趋势建模与局部残差修正过程，从而显著提升了缺失区间内部的高度恢复质量。


此外，Kalman Filter 在各项指标上均明显落后，表明传统线性状态估计方法难以适应分钟级长缺失轨迹恢复中的复杂动态变化。综合来看，本文方法的优势主要体现在高度维度及缺失区间内部的恢复能力上，这与跨洋长缺失轨迹恢复任务中对结果连续性、边界稳定性和实际可用性的要求是一致的。换言之，本文方法的贡献并不在于单纯压低所有维度的平均误差，而在于针对任务中最关键、最困难的高度恢复问题给出了更有效的解决方案。

模型	参数量	平均每轮训练时间 (s)	训练总时间 (s)	表现最好轮次
OurMethod	552,370	44.2	1061.6	24
UniLSTM	268,841	39.6	951.5	24
Kalman Filter	931	21.9	526.8	24
BiLSTM	536,751	45.1	1082.8	24
CNN+LSTM	641,967	20.6	495.4	24
LSTM+Attention	932,271	22.9	550.7	24

模型	参数量	平均每轮训练时间 (s)	训练总时间 (s)	表现最好轮次
Transformer	800,431	24.7	592.9	19

如表 X 所示，各模型在参数量、计算复杂度及训练时间上存在显著差异。本文提出的 OurMethod 训练参数量与 UniLSTM、BiLSTM 接近，训练时间约为 1000s 左右；Transformer 虽每轮训练时间略短，但在高度恢复指标上显著落后，且参数量高达 80 万，计算资源消耗大。Kalman Filter 尽管训练较快，总耗时仅 527 秒，但恢复性能明显偏低，无法满足任务需求。由此可见，OurMethod 在性能与训练效率之间实现了最佳平衡，在保持合理模型规模和训练成本的前提下，其高度恢复在缺失区间内取得最佳结果。






颜色统一：

在真实 ADS-C 数据上的效果


1. 真实 adsc 高度对比，10*2

2. 真实 adsc 3d 对比 4


3. Adsb 测试数据对比




AFR162



BOX303



THY5



VJA533

5 总结

参考文献

- [1] Kwak N J, Lee B Y. The Evolution and Taxonomy of Deep Learning Models for Aircraft Trajectory Prediction: A Review of Performance and Future Directions[J]. Applied Sciences, 2025, 15(19): 10739.
- [2] Xie X, Tian Y, Li J, et al. Shifting from physical models to learning methods for trajectory prediction: A review[J]. Expert Systems with Applications, 2025: 129303.
- [3] Shafienya H, Regan A C. 4D flight trajectory prediction using a hybrid Deep Learning prediction method based on ADS-B technology: A case study of Hartsfield–Jackson Atlanta International Airport (ATL)[J]. Transportation Research Part C: Emerging Technologies, 2022, 144: 103878.
- [4] Deng C, Choi H C, Park H, et al. Trajectory pattern identification and classification for real-time air traffic applications in Area Navigation terminal airspace[J]. Transportation Research Part C: Emerging Technologies, 2022, 142: 103765.
- [5] Luo P, Wang B, Li T, et al. ADS-B anomaly data detection model based on VAE-SVDD[J]. Computers & Security, 2021, 104: 102213.
- [6] Li J, Peng X, Bian L, et al. Research on fine-grained aircraft taxiing time prediction and conflict avoidance strategies[J]. Transportation Research Part C: Emerging Technologies, 2026, 186: 105585.
- [7] Carmona M A A, Nieto F S, Gallego C E V. A data-driven methodology for characterization of a terminal manoeuvring area in multi-airport systems[J]. Transportation Research Part C: Emerging Technologies, 2020, 111: 185-209.
- [8] Yang Z, Kang X, Gong Y, et al. Aircraft trajectory prediction and aviation safety in ADS-B failure conditions based on neural network[J]. Scientific reports, 2023, 13(1): 19677.
- [9] Shan R, Dong L, Li K, et al. A deep learning framework for predicting aircraft trajectories from sparse satellite observations[J]. Scientific Reports, 2025, 15(1): 43100.
- [10] OpenSky Report 2025: Improving Crowdsourced Flight Trajectories with ADS-C Data Sun J, Olive X, Strohmeier M, et al. OpenSky Report 2025: Improving Crowdsourced Flight Trajectories with ADS-C Data[C]//2025 Integrated Communications, Navigation and Surveillance Conference (ICNS). IEEE, 2025: 1-8.
- [11] 赵巍飞,于克非.星基广播式自动相关监视系统监视数据空中位置信息质量分析[J].科学技术与工程,2018,18(14):279-284.
- [12] Yin Y, Zhang S, Zhang Y, et al. Aircraft trajectory prediction in terminal airspace with intenti

- ons derived from local history[J]. *Neurocomputing*, 2025, 615: 128843.
- [13] Zhu H, Tong Q, Hu J, et al. Altitude aware trajectory prediction methods for non towered terminal airspace[J]. *Scientific Reports*, 2025, 15(1): 26810.
- [14] 陶冶,汤锦辉,闫震,等.融合表征转换与模式回归的航迹插补方法[J].*航空学报*,2026,47(01):272-293.
- [15] Dong X, Tian Y, Dai L, et al. A new accurate aircraft trajectory prediction in terminal airspace based on spatio-temporal attention mechanism[J]. *Aerospace*, 2024, 11(9): 718.
- [16] 王涛波, 黄宝军. 基于改进卡尔曼滤波的四维飞行航迹预测模型[J]. *计算机应用*, 2014, 34(6): 1812-1815.
- [17] Jeung H, Shen H T, Zhou X. Mining trajectory patterns using hidden Markov models[C]//International Conference on Data Warehousing and Knowledge Discovery. Berlin, Heidelberg: Springer Berlin Heidelberg, 2007: 470-480.
- [18] Ayala D, Ayala R, Vidal L S, et al. Neural Networks for Aircraft Trajectory Prediction: Answering Open Questions About Their Performance[J]. *IEEE Access*, 2023, 11: 26593 – 26610.
- [19] Xu Y, Pan Q, Wang Z, Hu B. A Novel Trajectory Prediction Method Based on CNN, BiLSTM, and Multi-Head Attention Mechanism[J]. *Aerospace*, 2024, 11(10): 822.
- [20] Ma L, Meng X, Wu Z. Data-Driven 4D Trajectory Prediction Model Using Attention-TCN-GRU[J]. *Aerospace*, 2024, 11(4): 313.
- [21] Guo D, Wu E Q, Wu Y, et al. FlightBERT: Binary Encoding Representation for Flight Trajectory Prediction[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2023, 24(2): 1828 – 1842.
- [22] Guo D, Zhang Z, Yan Z, et al. FlightBERT++: A Non-autoregressive Multi-Horizon Flight Trajectory Prediction Framework[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(1): 127 – 134.
- [23] Ge C, Zhang J, Wang L, et al. PC-Transformer: Probabilistic flight trajectory prediction with multi-stage predictive coding[J]. *Aerospace Science and Technology*, 2025: 110910.
- [24] Guo D, Zhang Z, Liu J, et al. Multi-horizon flight trajectory prediction enabled by time-frequency wavelet transform[J]. *Nature communications*, 2025.
- [25] Dai L, Zhang B, Chang Y, et al. CoDRE-Net: Collaborative dual-domain representation enhancement network for flight trajectory prediction[J]. *Neurocomputing*, 2025: 132007.
- [26] Dong X, Tian Y, Dai L, et al. A new accurate aircraft trajectory prediction in terminal airspace based on spatio-temporal attention mechanism[J]. *Aerospace*, 2024, 11(9): 718.
- [27] Yin Y, Zhang S, Zhang Y, et al. Aircraft trajectory prediction in terminal airspace with intentions derived from local history[J]. *Neurocomputing*, 2025, 615: 128843.
- [28] Chu X, Zeng W, Wu L. Joint prediction of multi-aircraft trajectories in terminal airspace: A FL

- ight Pattern-Guided Social Long-Short Term Memory network[J]. Engineering Applications of Artificial Intelligence, 2025, 147: 110325.
- [29] Wang L, Wang X, Zhang J, et al. FTIM: An end-to-end flight trajectory imputation method[J]. Aerospace Science and Technology, 2026, 168: 111031.
- [30] Galdelli A, Narang G, Tomassini S, et al. Data imputation in large and small-scale spatiotemporal time series gaps using BackForward Bi-LSTM[J]. Journal of Big Data, 2025, 12(1): 115.
- [31] Ma J, Roncoli C, Ren G, et al. Vehicle trajectory reconstruction from sparse data using a hybrid approach[J]. Journal of Transportation Engineering, Part A: Systems, 2025, 151(2): 04024108.
- [32] Alligier R, Gianazza D. Learning aircraft operational factors to improve aircraft climb prediction: A large scale multi-airport study[J]. Transportation research part C: emerging technologies, 2018, 96: 72-95.
- [33] Gallego C E V, Comendador V F G, Nieto F J S, et al. Analysis of air traffic control operational impact on aircraft vertical profiles supported by machine learning[J]. Transportation research part C: emerging technologies, 2018, 95: 883-903.
- [34] Rohani A S, Puranik T G, Kalyanam K M. Machine Learning Approach for Aircraft Performance Model Parameter Estimation for Trajectory Prediction Applications[C]. 2023 IEEE/AIAA 42nd Digital Avionics Systems Conference (DASC), 2023. (ntrs.nasa.gov)
- [35] Wu L, Wang X, Chu R, et al. FlightPatchNet: Multi-Scale Patch Network with Differential Coding for Flight Trajectory Prediction[J]. arXiv preprint arXiv:2405.16200, 2024.
- [36] Pepper N, De Ath G, Carvell B, et al. A sector-specific probabilistic approach for 4D aircraft trajectory generation[J]. Transportation Research Part C: Emerging Technologies, 2025, 179: 105291.
- [37] Jarry G, Olive X. Generation of Vertical Profiles with Neural Ordinary Differential Equations Trained on Open Trajectory Data[J]. Journal of Open Aviation Science, 2026, 4(2).